

CGVM Transformer study in 2023 winter

>> Transformer 주차별 계획



>> Table of contents


- 1. What is Attention?
- 2. Self Attention
- 3. Multi-head Attention
- 4. Masked Self Attention

1

What is Attention?

RNN에 기반한 seq2seq 모델이 갖고 있는 두 가지 문제점

- 1. 고정된 크기의 벡터(context vector)에 모든 정보를 압축하기 때문에 정보손실 발생
- 2. RNN의 고질적인 문제인 gradient vanishing 문제가 존재




https://jalammar.github.io/visualizing-neural-machine-translation-mechanics-of-seq2seq-models-with-attention/

Attention 이란?


- 디코더에서 출력단어를 예측하는 매 시점(time step)마다 인코더에서의 전체 입력 문장을 다시 참고하게 하자.
- 단 예측해야할 단어와 연관이 있는 입력 단어 부분을 좀 더 집중해서


Attention 이란?

- 디코더에서 출력단어를 예측하는 매 시점(time step)마다 인코더에서의 전체 입력 문장을 다시 참고하게 하자.
- 단 예측해야할 단어와 연관이 있는 입력 단어 부분을 좀 더 집중해서



https://jalammar.github.io/visualizing-neural-machine-translation-mechanics-of-seq2seq-models-with-attention/





Query:

Key:

Value:

Query: t 시점의 디코더 셀에서의 은닉 상태들


Key: 모든 시점의 인코더 셀의 은닉 상태들

Value: 모든 시점의 인코더 셀의 은닉 상태들(유사도를 반영할)

Query: t 시점의 디코더 셀에서의 은닉 상태들

Key: 모든 시점의 인코더 셀의 은닉 상태들


Value: 모든 시점의 인코더 셀의 은닉 상태들(유사도를 반영할)





Query: t 시점의 디코더 셀에서의 은닉 상태들


Key: 모든 시점의 인코더 셀의 은닉 상태들


Value: 모든 시점의 인코더 셀의 은닉 상태들(유사도를 반영할)

















이때, Attention Weight layer에서 출력되는 값은
= (0.1 0 0 0.1) + (0.055 0 0 0.11) + (0.8 0.8 1.6 0) + (0.045 0.045 0 0)
으로 계산하면 된다.








- 쿼리, 키, 벨류를 생성하기 위해 가중치행렬 W^Q, W^K, W^V 를 곱해준다.
- W^Q, W^K, W^V는 학습 과정을 통해 갱신해야 할 값이다.


- 위 과정으로 생성된 쿼리와 키[™]를 곱해 attention score를 구한다.
- attention score의 값이 증대되는 문제를 보안하기 위해 sqrt(키 벡터의 차원) 값으로 나누어 준다.
- 이를 벨류에 곱해주면 최종적인 context vector Z 가 구해진다


2


Self Attention


"Self Attention"











Attention VS Self-Attention

Q,K,V

- Attention : Q는 Decoder Cell에서 도출되고, K와 V는 Encoder Cell에서 도출됨
- Self-Attention : Q, K, V는 모두 동일한 Vector(Embedding Vector)에서 도출됨

Time step

- Attention : Time-Step을 활용함.
- Self-Attention : Time-Step을 활용하지 않음.


방향성


- Attention은 왼쪽->오른쪽, 혹은 오른쪽->왼쪽의 방향으로 해석이 진행되는 Unidirectional한 Model이다
- Self-Attention은 (Encoder측에서) 오른쪽과 왼쪽에 있는 모든 단어를 활용하는 Bidirectional한 Model이다.


3


Multi-head Attention


"Multi-head Attention"
















Multi-head attention matrix











Masked Self Attention


"Masked self Attention"














Figure 1: The Transformer - model architecture.

Thank you

Hyoungbum Kim